Reporte Comparativo

¿Bajar más el error al añadir dos capas?

Al pasar de la topología original a la red más profunda, el error no disminuyó; por el contrario, se estancó y el rendimiento empeoró notoriamente. Este comportamiento fue consistente tanto en la implementación manual con NumPy como en la de Keras. En la notebook de NumPy, la red original logró hacer descender el error de forma fluida, pero al usar la red profunda, la curva se aplanó casi de inmediato en un valor alto. En Keras ocurrió un fenómeno similar: la red original bajó la pérdida hasta 0.18 aproximadamente, mientras que la profunda se estancó cerca de 0.22, demostrando una clara incapacidad para seguir aprendiendo.

¿Las curvas se parecen con la misma topología?

Aunque ambas redes originales compartían la misma topología, tasa de aprendizaje y número de épocas, las curvas presentaron ligeras diferencias visuales y escalas de error distintas. Estas diferencias se explican por detalles de implementación interna:

Inicialización de pesos: En NumPy los pesos se inicializaron con una distribución aleatoria básica uniforme (valores entre -1 y 1 o similares), mientras que Keras utiliza por defecto inicializadores estadísticamente más robustos, lo que le da un mejor punto de partida al modelo.

Orden de los datos y Vectorización: Keras maneja el (shuffling) de los datos y el cálculo matricial de los gradientes de forma altamente optimizada por lotes. La implementación manual procesa las actualizaciones con ciclos ”for” anidados que pueden afectar la trayectoria exacta del descenso del gradiente iteración por iteración.

Con sigmoides apiladas y MSE, ¿tiene sentido que una red más profunda no aprenda mejor en Iris?

Tiene algo de sentido decir que la red más profunda no haya aprendido mejor, y las gráficas de estancamiento son la prueba directa del problema del desvanecimiento del gradiente. En el algoritmo de Backpropagation, los errores se propagan hacia atrás multiplicando las derivadas de las funciones de activación. La derivada de la función sigmoide tiene un valor máximo de 0.25. Al tener cuatro capas de sigmoides apiladas, multiplicamos fracciones pequeñas varias veces, haciendo que el gradiente (el valor de ajuste) que llega a las primeras capas (Capa 1 y Capa 2) sea prácticamente cero. Como los pesos iniciales no se actualizan, la red deja de aprender. Además, el dataset Iris es un problema pequeño y casi linealmente separable. Usar una red de 4 capas es una arquitectura innecesariamente compleja para este conjunto de datos, lo que dificulta la convergencia sin aportar ningún beneficio real a la clasificación.