Reporte: Q-learning

¿Por qué el camino de 13 pasos, pegado al acantilado, es óptimo?

Básicamente porque como no tenemos descuento ($\gamma = 1$) y cada movimiento nos cuesta -1, lo que nos importa es llegar a la meta con la menor cantidad de pasos posible. Si nos pusiéramos a rodear por las filas de arriba, daríamos más vuelta y acumularíamos más penalizaciones. El camino de la fila 2, pegaditos al acantilado, es literal la ruta más corta: subes un paso, caminas 11 derecho y bajas uno. Son 13 pasos exactos, dándonos el mejor retorno posible de -13.

¿Por qué la curva de entrenamiento queda por debajo de −13 aunque la política greedy ya sea óptima?

Eso pasa porque durante el entrenamiento tenemos activado el $\epsilon = 0.1$. O sea, el 10% del tiempo el agente anda de rebelde tomando acciones al azar en lugar de hacerle caso a lo que ya aprendió en su tabla Q. Cada vez que se equivoca y se cae al acantilado, le cae un castigo bien pesado de -100 puntos, lo que hunde la recompensa de ese episodio. Aunque el agente ya se sepa el camino perfecto, esas caídas por andar explorando hacen que el promedio de entrenamiento se quede por debajo de los -13.

En el paso que cae al acantilado, ¿cuál es s' en el backup de Q-learning, y por qué ese backup no trata el acantilado como estado terminal?

Ahí el estado siguiente (s') es la casilla de inicio **S** (3, 0). Y no se trata como estado terminal porque, según las reglas del Cliff Walking, caerte al abismo no termina el episodio; solo te penaliza con -100 y te mandan de regreso a la fuerza a la salida para seguir intentándolo. Por eso en la fórmula de Q-learning no le puedes poner un cero de estado final, sino que tienes que calcular el valor máximo tomando en cuenta que el agente vuelve a empezar desde **S**.